

AI Agent

1주차



What is An AI Agent?

Agent vs Workflow — 목표, 환경, 자율성, 성공과 실패

Example

- “이번 주 AI Agent 관련 중요한 연구를 찾아서 내가 읽어야 할 논문 5편을 추천해 줘.”
- “서울에서 부산까지 가장 저렴한 항공편을 찾아서 예약해 줘.”

실제로 해야 할 일



LLM, Workflow, Agent

- LLM

→ 답을 생성

- Workflow

→ 미리 정의된 절차를 실행

- Agent


→ 상황을 관찰하면서

다음 행동을 선택하고


목표가 달성될 때까지 반복

LLM Application의 가장 단순한 형태

- 패턴




- 예:



- 이 구조에서는 모델이 외부 세계를 변화시키지 않는다
- 입력을 받아서 출력을 생성한다

LLM + Tool = Agent ?



- 예를 들어 프로그램이 항상
`result = search(query)`
`answer = llm(result)`
- 위 순서로 실행된다면 LLM 모델은 실제 실행 경로를 선택하지 않는다

Workflow

- 실행절차가 주로 개발자에 의해 미리 결정된 시스템
 - Input → Step A → Step B → Step C → Output
 - 예: PDF upload → Text extraction → LLM summarization → Translation → Save
- Workflow의 장점
 - 예측 가능
 - 테스트하기 쉬움
 - 비용 예측 가능
 - latency 예측 가능
 - 실패 지점이 명확
 - 보안 경계를 정의하기 쉬움
- 가능하다면 Workflow가 더 좋은 설계일 수 있다

Agent

- 목표를 달성하기 위해 환경을 관찰하고
- 다음 행동을 선택하며,
- 그 결과를 다시 관찰하는 과정을 반복하는 시스템


- In Workflow, developer decides

$A \rightarrow B \rightarrow C \rightarrow D$

- In Agent, model decides

- Tool A
- Tool B
- Tool C
- STOP

- 누가 다음 행동을 결정하는가?



Agent Loop

while not done:

observe()

decide()

act()

evaluate()

Observation



Reason / Decide



Action



Environment



Observation



Agent – Goal

- Goal: Agent가 달성해야 할 목표

“논문을 찾아라”



“2026년에 발표된 AI Agent evaluation 논문 중 강의에서 사용할 가치가 높은 논문 5편을 찾아 선택 이유와 근거를 제시하라.”

- Goal이 불명확하면 Agent가 잘 동작하는지 평가할 수 없다

→ Goal specification과 evaluation은 연결되어 있다

Agent – Environment, Observation

- Environment는 Agent가 관찰하고 행동할 수 있는 외부 세계
 - 예: Web, Files, Database, Terminal, GitHub, Email, Calendar, Robot, Other Agents
- LLM 내부와 외부 구분
 - 검색 결과, 파일, terminal 실행 결과 등은 환경에서 얻은 observatio이다
- Observation은 Agent의 Action결과로 얻는 정보
 - `search("AI agent evaluation") → [ paper A, paper B, paper C ]`
 - `run_test() → 3 tests failed`

Agent – Action

- Agent가 환경에 취할 수 있는 행동
 - `search(query)`, `open_document(id)`, `run_python(code)`, `read_file(path)`, `write_file(path)`, `send_email(...)`
- Action의 능력은 가능한 Action의 집합에 의해 제한된다
- “LLM이 아무리 똑똑해도 `send_email()`이라는 tool이 없다면 이메일을 보낼 수 있는가?”
→ 없다
- 모델 intelligence와 system capability를 구분하여야 한다

Agent – State

- 시간 t 에서
 - Previous actions
 - Previous observations
 - Intermediate results
 - Remaining budget
 - Current plan
- Agent는 매 순간 처음부터 다시 생각하는 시스템이 아니다

Agent – Stop condition

- STOP? Agent는 다음을 결정하여야 한다
 - 계속 행동할 것인가?
 - 목표가 달성되었는가?
 - 예: 논문 5개를 찾음 → 정말 충분한가? → 추가 검색?
- Stop condition으로 Agent가 완성된다
- Success $\neq$ Stop
 - Task succeeded $\neq$ Agent stopped
- Agent가 “완료했습니다”라고 출력했다고 성공한 것은 아니다

Autonomy

시스템의 결정 중 얼마나 많은 부분을 모델에게 위임하는가?

Low

High

Script

- Workflow
 - Router
 - Tool Agent
 - Planning Agent
 - Long-running Agent

- Agent / Non-Agent를 완전히 이분법으로 보는 것보다 autonomy의 정도를 보는 것이 더 유용하다.

Autonomy 비용

- Autonomy가 높아지면
- Flexibility, Adaptability가 높아지고,
- 동시에 다음도 높아 진다
- Uncertainty,
- Failure surface,
- Cost variance,
- Security risk,
- Evaluation difficulty

Agent 사용 판단 기준

① 다음 행동을 미리 정할 수 있는가?

Yes → Workflow 가능성이 높음

② 중간 결과에 따라 행동이 달라지는가?

Yes → Agent 후보

③ 환경이 불확실한가?

Yes → Agent 후보

④ 실패 비용이 큰가?


Yes → 오히려 autonomy를 제한해야 할 수도 있음

Workflow or Agent?


- 매일 밤 11시에 서버 로그를 가져와 오류 수를 세고 관리자에게 보고한다.
- 서버 장애가 발생하면 로그를 조사하고, 관련 코드를 검색하고, 가능한 원인을 세운 뒤 필요한 diagnostic tool을 선택해서 원인을 추적한다.
- “내 계좌를 관리해서 수익을 최대화해.”
- **Permission, Approval, Budget, Action boundary, Audit**

Action Failure Map

Agent Failure



Agent Diagram



Questions

A. 문서를 한국어로 번역한다.

→ Workflow / LLM application

B. 사용자가 보낸 영수증을 읽어 정해진 DB schema에 저장한다.

→ 주로 Workflow

C. 여행 조건을 조사하고 항공·호텔을 비교하며 필요하면 검색 전략을 바꾼다.

→ Agent 후보

D. GitHub issue를 읽고 코드를 수정하고 test가 통과할 때까지 반복한다.

→ Agent 후보

E. 매일 새로운 논문을 가져와 요약한다.

→ 반드시 Agent일 필요 없음

요약

1. Agent $\neq$ LLM
2. Agent $\neq$ Tool Calling
3. Agent의 핵심은 Observation $\rightarrow$ Action $\rightarrow$ Observation
4. Autonomy에는 비용과 위험이 따른다
5. Agent를 사용하기 전에 Workflow로 가능한지 묻는다

마지막 문장:

Use the simplest system that can reliably solve the problem.